

低秩稀疏表示算法求解

1. 鲁棒性主成分分析 (Robust Principal Component Analysis, RPCA)

$$\min_{L,E} \text{rank}(L) + \lambda \|E\|_0 \quad s.t. X = L + E \quad (\text{RPCA})$$

$$\min_{L,E} \|L\|_* + \lambda \|E\|_1 \quad s.t. X = L + E \quad (\text{RPCA 最终求解模型})$$

假设背景存在单一的子空间，没有考虑到高光谱影像中复杂的背景地物信息

2. 低秩表示算法 (Low Rank Representation)

$$\min_Z \text{rank}(Z) \quad s.t. X = DZ \quad (\text{LRR 初始模型})$$

$$\min_{Z,E} \|Z\|_* + \lambda \|E\|_{2,1} \quad s.t. X = DZ + E \quad (\text{LRR 最终求解模型})$$

3. 低秩和稀疏表示 (Low Rank and Sparse Representation)

$$\min_{Z,E} \|Z\|_* + \|Z\|_1 + \lambda \|E\|_{2,1} \quad s.t. X = DZ + E \quad (\text{LRASR 最终求解模型})$$

4. 字典学习的方法

上面方法采用整个矩阵作为过完备字典，实际运算计算代价较大，因此采用了学习字典方法，用少量的原子构成字典

$$x = D\alpha + v \quad (\text{系数}\alpha\text{是稀疏的})$$

$$\hat{\alpha} = \underset{\alpha}{\text{argmin}} \|x - D\alpha\|_2 + \gamma \|\alpha\|_1 \quad (\text{采用稀疏编码方法来求稀疏系数})$$

$$D^{(n+1)} = D^n - \mu \sum_{i=1}^M (D^n \alpha_i - x_i) \alpha_i^T \quad (\text{字典学习过程})$$

5. 单/多局部窗口低秩表示模型 (SLW_LRRSTO/MLW_LRRSTO)

$$\min_{Z,E} \|Z\|_* + \eta \|Z - \tilde{Z}\|_F^2 + \lambda \|E\|_{2,1} \quad s.t. X = DZ + E, \mathbf{1}_d^T \cdot Z = \mathbf{1}_n^T$$

矩阵的各种范数含义：

$\|\cdot\|_*$ 核范数，矩阵的奇异值之和，用于 $\text{rank}(\cdot)$ 的松弛求解

$\|\cdot\|_0$ 0 范数，矩阵中非零元素的个数，通常松弛到 $\|\cdot\|_1$ 之后进行求解

$\|\cdot\|_1$ 1 范数，矩阵元素的绝对值之和（稀疏规则算子，L1 范数是 L0 范数的最优凸近似，而且它比 L0 范数要容易优化求解）

$\|E\|_{2,1}$ $\ell_{1,2}$ 范数，矩阵中各列的 2 范数之和

$\|\cdot\|_F$ F 范数，矩阵元素的绝对值的平方和，再开方

参数 λ 称为正则化参数，用于控制稀疏解的稀疏度， λ 取值越大，解 α 就越稀疏。当正则化参数 λ 足够大时，解 α 为零向量；随着 λ 的逐渐减小，解向量 α 的稀疏度也逐渐减小；当 λ 逐渐减小到 0 时，解向量 α 便变成了 $\|y - X_s \alpha\|_2^2$ 最小化的向量。

Part I RPCA 求解的具体过程：

$$\min_{Z,E} \|A\|_* + \lambda \|E\|_1 \quad s.t. X = A + E$$

利用增广拉格朗日法求解：

$$\begin{aligned} L(A, E, Y, \mu) &= \|A\|_* + \lambda \|E\|_1 + \langle Y, X - A - E \rangle + \frac{\mu}{2} \|X - A - E\|_F^2 \\ &= \|A\|_* + \lambda \|E\|_1 + \left[\frac{\mu}{2} \|X - A - E\|_F^2 + \frac{Y}{\mu} \right] - \frac{1}{2\mu} \|Y\|_F^2 \end{aligned}$$

利用配方法化简：

$$\begin{aligned} &\langle Y, X - A - E \rangle + \frac{\mu}{2} \|X - A - E\|_F^2 \\ &= \frac{\mu}{2} \left[\|X - A - E\|_F^2 + \frac{2}{\mu} \langle Y, X - A - E \rangle \right] \\ &= \frac{\mu}{2} \left[\|X - A - E\|_F^2 + 2 \left\langle \frac{Y}{\mu}, X - A - E \right\rangle \right] \\ &= \frac{\mu}{2} \left[\|X - A - E\|_F^2 + 2 \left\langle \frac{Y}{\mu}, X - A - E \right\rangle + \left\| \frac{Y}{\mu} \right\|_F^2 - \left\| \frac{Y}{\mu} \right\|_F^2 \right] \\ &= \frac{\mu}{2} \left[\left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 - \left\| \frac{Y}{\mu} \right\|_F^2 \right] \\ &= \frac{\mu}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 - \frac{\mu}{2} \left\| \frac{Y}{\mu} \right\|_F^2 \\ &= \frac{\mu}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 - \frac{1}{2\mu} \|Y\|_F^2 \end{aligned}$$

分别更新 A、E、Y、 μ ：

1) 固定 E, Y 更新 A:

$$\begin{aligned} (U, S, V) &= \text{svd}(X - E_k + \mu_k^{-1} Y_k) \\ A_{k+1} &= U S_{\mu_k^{-1}} [S] V^T \end{aligned}$$

2) 固定 A, Y 更新 E:

$$E_{k+1} = S_{\lambda \mu_k^{-1}} [X - A_{k+1} + \mu_k^{-1} Y_k]$$

3) 固定 A, E 更新 Y:

$$Y_{k+1} = Y_k + \mu_k(X - A_{k+1} - E_{k+1})$$

4) 更新 μ

$$\mu_{k+1} = \rho \mu_k$$

相关的公式:

① 软阈值收缩算子 (用于升级 E 的计算):

$$S_\varepsilon[W] = \operatorname{argmin}_X \varepsilon \|X\|_1 + \frac{1}{2} \|X - W\|_F^2 \quad \text{L1 范数求解式 (用于升级 E)}$$

$$S_\varepsilon[x] = \begin{cases} x - \varepsilon, & \text{if } x > \varepsilon \\ x + \varepsilon, & \text{if } x < -\varepsilon \\ 0, & \text{otherwise} \end{cases}$$

② 奇异值运算 (用于升级 A 的计算):

$$US_\varepsilon[S]V^T = \operatorname{argmin}_X \varepsilon \|X\|_* + \frac{1}{2} \|X - W\|_F^2 \quad \text{核范数求解式 (用于升级 A)}$$

具体的升级计算过程:

1. 固定 E, Y 更新 A

$$L(A, E, Y, \mu) = \|A\|_* + \lambda \|E\|_1 + \frac{\mu}{2} \|X - A - E + \frac{Y}{\mu}\|_F^2 - \frac{1}{2\mu} \|Y\|_F^2 \quad (\text{化简之后的式子})$$

去掉 E、Y 相关项, 只保留与 A 相关的项。

$$L(A, E, Y, \mu) \rightarrow \|A\|_* + \frac{\mu}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2$$

$$L(A, E, Y, \mu) \rightarrow \mu \left(\frac{1}{\mu} \|A\|_* + \frac{1}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 \right)$$

去掉 μ , 后面提出来一个负号:

$$L(A, E, Y, \mu) \rightarrow \frac{1}{\mu} \|A\|_* + \frac{1}{2} \left\| A - \left(X - E + \frac{Y}{\mu} \right) \right\|_F^2$$

形势化简完成, 采用奇异值运算 (核范数), 其中 $\varepsilon = \frac{1}{\mu}$, $W = X - E + \frac{Y}{\mu}$

更新式如下:

$$(U, S, V) = \operatorname{svd}(X - E_k + \mu_k^{-1} Y_k) \\ A_{k+1} = US_{\mu_k^{-1}}[S]V^T$$

2. 固定 A, Y 更新 E

$$L(A, E, Y, \mu) = \|A\|_* + \lambda \|E\|_1 + \frac{\mu}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 - \frac{1}{2\mu} \|Y\|_F^2 \quad (\text{化简之后的式子})$$

去掉 A、Y 相关项，只保留与 E 相关的项。

$$L(A, E, Y, \mu) \rightarrow \lambda \|E\|_1 + \frac{\mu}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2$$

$$L(A, E, Y, \mu) \rightarrow \mu \left(\frac{\lambda}{\mu} \|E\|_1 + \frac{1}{2} \left\| X - A - E + \frac{Y}{\mu} \right\|_F^2 \right)$$

去掉 μ ，后面提出来一个负号：

$$L(A, E, Y, \mu) \rightarrow \frac{\lambda}{\mu} \|E\|_1 + \frac{1}{2} \left\| E - \left(X - A + \frac{Y}{\mu} \right) \right\|_F^2$$

形势化简完成，采用软阈值收缩算子运算（L1 范数），其中 $\varepsilon = \frac{\lambda}{\mu}$ ， $W = X - A + \frac{Y}{\mu}$

更新式如下：

$$E_{k+1} = S_{\lambda \mu_k^{-1}} [X - A_{k+1} + \mu_k^{-1} Y_k]$$

3. 固定 A, E 更新 Y

原始式子如下：

$$L(A, E, Y, \mu) = \|A\|_* + \lambda \|E\|_1 + \langle Y, X - A - E \rangle + \frac{\mu}{2} \|X - A - E\|_F^2$$

与 Y 相关的式子：

$$L(A, E, Y, \mu) \rightarrow \langle Y, X - A - E \rangle$$

其中 Y 为系数，对其求导，梯度为 $X - A - E$

更新式如下：

$$Y_{k+1} = Y_k + \mu_k (X - A_{k+1} - E_{k+1})$$

Part II 低秩表示 (LRR) 算法求解：

$$\min_{Z, E} \|Z\|_* + \lambda \|E\|_{2,1} \quad s.t. X = DZ + E \quad (\text{LRR 公式})$$

采用增广拉格朗日法进行求解，不同于 RPCA 算法求解，求解过程中需要引入辅

助变量 J，使得目标函数具有可分性，求解公式等价于：

$$\min_{Z, E} \|J\|_* + \lambda \|E\|_{2,1} \quad s.t. X = DZ + E, \quad Z = J$$

构造增广拉格朗日函数：

$$L(J, Z, E, Y_1, Y_2, \mu) = \|J\|_* + \lambda \|E\|_{2,1} + \langle Y_1, X - DZ - E \rangle + \langle Y_2, Z - J \rangle \\ + \frac{\mu}{2} \|X - DZ - E\|_F^2 + \frac{\mu}{2} \|Z - J\|_F^2$$

对上式的两个平方项通过配方法分别进行化简：

$$L(J, Z, E, Y_1, Y_2, \mu) = \|J\|_* + \lambda \|E\|_{2,1} + \langle Y_1, X - DZ - E \rangle + \langle Y_2, Z - J \rangle \\ + \frac{\mu}{2} \|X - DZ - E\|_F^2 + \frac{\mu}{2} \|Z - J\|_F^2 \\ = \|J\|_* + \lambda \|E\|_{2,1} + \boxed{\frac{\mu}{2} \|X - DZ - E\|_F^2 + \langle Y_1, X - DZ - E \rangle} \\ \boxed{+ \frac{\mu}{2} \|Z - J\|_F^2 + \langle Y_2, Z - J \rangle} \\ = \|J\|_* + \lambda \|E\|_{2,1} + \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 + \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 \\ - \frac{1}{2\mu} (\|Y_1\|_F^2 + \|Y_2\|_F^2)$$

具体化简过程如下：

为了方便，下面分别拿出来对两个平方项进行配方法化简：

对于**第一项**进行化简，具体过程如下：

$$\frac{\mu}{2} \|X - DZ - E\|_F^2 + \langle Y_1, X - DZ - E \rangle \\ = \frac{\mu}{2} \left(\|X - DZ - E\|_F^2 + \frac{2}{\mu} \langle Y_1, X - DZ - E \rangle \right) \\ = \frac{\mu}{2} \left(\|X - DZ - E\|_F^2 + 2 \left\langle \frac{Y_1}{\mu}, X - DZ - E \right\rangle \right) \\ = \frac{\mu}{2} \left(\|X - DZ - E\|_F^2 + 2 \left\langle \frac{Y_1}{\mu}, X - DZ - E \right\rangle + \left\| \frac{Y_1}{\mu} \right\|_F^2 - \left\| \frac{Y_1}{\mu} \right\|_F^2 \right) \\ = \frac{\mu}{2} \left(\left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 - \left\| \frac{Y_1}{\mu} \right\|_F^2 \right) \\ = \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 - \frac{\mu}{2} \left\| \frac{Y_1}{\mu} \right\|_F^2 \\ = \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 - \frac{1}{2\mu} \|Y_1\|_F^2$$

对于**第二项**进行化简，具体过程如下：

$$\begin{aligned}
& \frac{\mu}{2} \|Z - J\|_F^2 + \langle Y_2, Z - J \rangle \\
&= \frac{\mu}{2} \left(\|Z - J\|_F^2 + \frac{2}{\mu} \langle Y_2, Z - J \rangle \right) \\
&= \frac{\mu}{2} \left(\|Z - J\|_F^2 + 2 \left\langle \frac{Y_2}{\mu}, Z - J \right\rangle + \left\| \frac{Y_2}{\mu} \right\|_F^2 - \left\| \frac{Y_2}{\mu} \right\|_F^2 \right) \\
&= \frac{\mu}{2} \left(\left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 - \left\| \frac{Y_2}{\mu} \right\|_F^2 \right) \\
&= \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 - \frac{\mu}{2} \left\| \frac{Y_2}{\mu} \right\|_F^2 \\
&= \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 - \frac{1}{2\mu} \|Y_2\|_F^2
\end{aligned}$$

具体的升级计算过程：

化简之后的 LRR 式为：

$$\begin{aligned}
L(J, Z, E, Y_1, Y_2, \mu) &= \|J\|_* + \lambda \|E\|_{2,1} + \frac{\mu}{2} \|X - DZ - E\|_F^2 + \frac{Y_1}{\mu} \left\| \frac{Y_1}{\mu} \right\|_F^2 + \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 \\
&\quad - \frac{1}{2\mu} (\|Y_1\|_F^2 + \|Y_2\|_F^2)
\end{aligned}$$

1. 固定 Z, E, Y₁, Y₂ 更新 J

式子中去掉其他项，只保存与 J 有关的项，则有

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \|J\|_* + \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2$$

对上述式子进行化简：

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \mu \left(\frac{1}{\mu} \|J\|_* + \frac{1}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 \right)$$

去掉 μ ，然后对后面提出一个负号，进行化简后为：

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \frac{1}{\mu} \|J\|_* + \frac{1}{2} \left\| J - \left(Z + \frac{Y_2}{\mu} \right) \right\|_F^2$$

根据奇异值运算形式，可得 $\varepsilon = \mu^{-1}$, $W = Z + \frac{Y_2}{\mu}$

$$\text{US}_\varepsilon[S]V^T = \operatorname{argmin}_X \varepsilon \|X\|_* + \frac{1}{2} \|X - W\|_F^2$$

(奇异值运算)

因此，最后更新式为：

$$(U, S, V) = \text{svd}\left(Z_k + \frac{Y_2}{\mu}\right)$$

$$J_{k+1} = US_{\mu_k^{-1}}[S]V^T$$

2. 固定 J, E, Y₁, Y₂ 更新 Z

去掉其他项，保留与 Z 有关的项

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 + \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2$$

上述式子因为是 F 范数的平方，所以不能使用软阈值收缩、奇异值运算等算子进行运算，此处对该式子的 Z 进行求导：

$$\begin{aligned} \frac{\partial L(J, Z, E, Y_1, Y_2, \mu)}{\partial Z} &= -\mu D^T \left(X - DZ - E + \frac{Y_1}{\mu} \right) + \mu \left(Z - J + \frac{Y_2}{\mu} \right) \\ &= -\mu \left(D^T X - D^T DZ - D^T E + \frac{D^T Y_1}{\mu} - Z + J - \frac{Y_2}{\mu} \right) \\ &= -\mu (D^T X - D^T E - (D^T D + I)Z + J + \mu^{-1}(D^T Y_1 - Y_2)) \end{aligned}$$

令式子等于 0，可得

$$D^T X - D^T E - (D^T D + I)Z + J + \mu^{-1}(D^T Y_1 - Y_2) = 0$$

即，

$$(D^T D + I)Z = D^T X - D^T E + J + \mu^{-1}(D^T Y_1 - Y_2)$$

因此，可得最后的关于 Z 的更新式为：

$$Z_{k+1} = (D^T D + I)^{-1} (D^T X - D^T E_k + J_{k+1} + \mu_k^{-1}(D^T Y_{1k} - Y_{2k}))$$

3. 固定 J, Z, Y₁, Y₂ 更新 E

去掉其他项，保留与 E 有关的项

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \lambda \|E\|_{2,1} + \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2$$

对以上式子进行格式化简

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \mu \left(\frac{\lambda}{\mu} \|E\|_{2,1} + \frac{1}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 \right)$$

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \mu \left(\frac{\lambda}{\mu} \|E\|_{2,1} + \frac{1}{2} \left\| E - \left(X - DZ + \frac{Y_1}{\mu} \right) \right\|_F^2 \right)$$

去掉括号最外面的 μ ，则有如下形势

$$E = \operatorname{argmin}_E \frac{\lambda}{\mu} \|E\|_{2,1} + \frac{1}{2} \left\| E - \left(X - DZ + \frac{Y_1}{\mu} \right) \right\|_F^2$$

该公式同软阈值收缩算子形式，其中 $\varepsilon = \lambda/\mu$ ， $W = X - DZ + \frac{Y_1}{\mu}$ ，故升级 E 的公式为：

$$E_{k+1} = S_{\lambda/\mu} \left[X - DZ + \frac{Y_1}{\mu} \right]$$

4. 固定 J, Z, E 更新 Y_1, Y_2

同样，去掉其他项，分别保留与 Y_1, Y_2 有关的项：

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \frac{\mu}{2} \left\| X - DZ - E + \frac{Y_1}{\mu} \right\|_F^2 - \frac{\|Y_1\|_F^2}{2\mu}$$

$$L(J, Z, E, Y_1, Y_2, \mu) \rightarrow \frac{\mu}{2} \left\| Z - J + \frac{Y_2}{\mu} \right\|_F^2 - \frac{\|Y_2\|_F^2}{2\mu}$$

两边对 Y_1, Y_2 分别求导：

$$\frac{\partial L(J, Z, E, Y_1, Y_2, \mu)}{\partial Y_1} = X - DZ - E + \frac{Y_1}{\mu} - \frac{Y_1}{\mu}$$

$$\frac{\partial L(J, Z, E, Y_1, Y_2, \mu)}{\partial Y_2} = Z - J + \frac{Y_2}{\mu} - \frac{Y_2}{\mu}$$

此时需要注意，最后的两项不能直接消去，可令其中一个为 Y_{1k+1} ，另一个为 Y_{1k} ，

同时令求导式等于 0，可得 Y_1 的更新式为：

$$Y_{1k+1} = Y_{1k} + \mu_k (X - DZ_{k+1} - E_{k+1})$$

同理可得 Y_2 的更新式为：

$$Y_{2k+1} = Y_{2k} + \mu_k (Z_{k+1} - J_{k+1})$$

5. 升级 μ 的式子为

$$\mu = \min(\rho\mu, \mu_{max})$$